

Real-Time Sphere Sweeping Stereo from Multiview Fisheye Images

Andreas Meuleman

Hyeonjoong Jang

Daniel S. Jeon

Min H. Kim

KAIST

Abstract

A set of cameras with fisheye lenses have been used to capture a wide field of view. The traditional scan-line stereo algorithms based on epipolar geometry are directly inapplicable to this non-pinhole camera setup due to optical characteristics of fisheye lenses; hence, existing complete 360° RGB-D imaging systems have rarely achieved real-time performance yet. In this paper, we introduce an efficient sphere-sweeping stereo that can run directly on multi-view fisheye images without requiring additional spherical rectification. Our main contributions are: First, we introduce an adaptive spherical matching method that accounts for each input fisheye camera's resolving power concerning spherical distortion. Second, we propose a fast inter-scale bilateral cost volume filtering method that refines distance in noisy and textureless regions with optimal complexity of $O(n)$. It enables real-time dense distance estimation while preserving edges. Lastly, the fisheye color and distance images are seamlessly combined into a complete 360° RGB-D image via fast inpainting of the dense distance map. We demonstrate an embedded 360° RGB-D imaging prototype composed of a mobile GPU and four fisheye cameras. Our prototype is capable of capturing complete 360° RGB-D videos with a resolution of two megapixels at 29 fps. Results demonstrate that our real-time method outperforms traditional omnidirectional stereo and learning-based omnidirectional stereo in terms of accuracy and performance.

1. Introduction

Efficient and accurate understanding of the appearance and structure of 3D scenes is a vital capability of computer vision used in many applications, such as autonomous vehicle [38], robotics [60], augmented/mixed reality [51, 5], etc. Conventional stereo cameras with ordinary lenses provide a narrow field of view, insufficient to capture scenes in all directions. In order to capture scenes in all directions, we can build a multi-camera setup like a light-field camera array [6, 44], but it significantly increases manufacturing cost, in addition to computational cost for processing multiple input, to obtain omnidirectional panorama and distance.




Figure 1: (a) Our prototype built on an embedded system. (b) Four input fisheye images. (c) & (d) Our results of omnidirectional panorama and dense distance map (shown as the inverse of distance). It took just 34 ms per frame on this device. Refer to the supplemental video for real-time demo.

It is a natural choice to use a smaller number of fisheye lenses to reduce the number of cameras while covering all directions. The omnidirectional camera configuration with multiple fisheye lenses suffers from an inevitable tradeoff between performance and accuracy when computing full 360° panorama and distance due to the optical characteristics of fisheye lenses presented subsequently.

First, the conventional pinhole camera model is invalid for field of views of 180° or more even when the calibration model can accommodate a wider FoV [25, 12, 53]. Accordingly, unlike ordinary stereo, we cannot find stereo correspondence rapidly by sweeping plane candidates [24] in wide angle fisheye images. Second, epipolar lines on fisheye images are curved [39, 50], requiring warp-aware correspondence search with spatial variation, significantly increasing computational costs. An equirectangular or a latitude-longitude projection can be employed to obtain straight epipolar lines [52, 34]. However, it introduces se-

マルチビュー魚眼画像からのリアルタイムスフィアスイーピングステレオ

アンドレアス・ミュールマチャン・ヒョンジュン ダニエル・S・チョンミン・H・キム

KAISTの

要約

魚眼レンズを備えた一連のカメラは、広い視野をキャプチャするために使用されています。エピソード形状に基づく従来のスキャンラインステレオアルゴリズムは、魚眼レンズの光学特性により、この非ピンホールカメラのセットアップには直接適用できません。そのため、既存の完全な360RGB-Dイメージングシステムは、まだリアルタイム性能を達成することはめったにありません。このホワイトペーパーでは、追加の球面補正を必要とせずにマルチビュー魚眼画像で直接実行できる効率的な球スイープステレオを紹介します。私たちの主な貢献は、まず、球面歪みに関する各入力魚眼カメラの解像度を考慮した適応球面マッチング法を導入することです。次に、 $O(n)$ の最適な複雑さでノイズが多くテクスチャのない領域の距離を微調整する、高速なスケール間二国間コストボリュームフィルタリング方法を提案します。これにより、エッジを維持しながら、リアルタイムの密な距離推定が可能になります。最後に、魚眼カラーと距離画像は、密集した距離マップの高速インペインティングにより、完全な360RGB-D画像にシームレスに結合されます。モバイルGPUと4台の魚眼カメラで構成された組み込み360RGB-Dイメージングプロトタイプをデモします。私たちのプロトタイプは、29fpsで2メガピクセルの解像度で完全な360RGB-Dビデオをキャプチャすることができます。結果は、当社のリアルタイム手法が、精度とパフォーマンスの点で、従来の全方向性ステレオおよび学習ベースの全方向性ステレオよりも優れていることを示しています。

1.はじめに 3Dシーンの外観と構造を効率的かつ正確に理解することは、自律走行車[38]、ロボット工学[60]、拡張/複合現実[51、5]など、多くのアプリケーションで使用されるコンピュータビジョンの重要な機能です。従来のステレオカメラと一般的なレンズは視野が狭く、全方向のシーンを捉えるには不十分でした。全方向のシーンをキャプチャするために、ライトフィールドカメラアレイ[6、44]のようなマルチカメラセットアップを構築できますが、全方向のパノラマと距離を取得するための複数の入力を処理するための計算コストに加えて、製造コストが大幅に増加します。




図 1:(a)組み込みシステム上に構築されたプロトタイプ。(b)4つの入力魚眼画像。(c) & (d) 全方位パノラマと密集距離マップの結果 (距離の逆数として表示)。このデバイスでは、フレームあたりわずか34ミリ秒しかかかりませんでした。リアルタイム デモについては、補足ビデオを参照してください。

魚眼レンズの数を減らして、すべての方向をカバーしながらカメラの数を減らすことは自然な選択です。複数の魚眼レンズを備えた全方位カメラ構成は、その後に提示される魚眼レンズの光学特性により、完全な360パノラマと距離を計算するとき、パフォーマンスと精度の間の必然的なトレードオフに悩まされます。

まず、従来のピンホールカメラモデルは、キャリブレーションモデルがより広いFoVに対応できる場合でも、180以上の視野には無効です[25、12、53]。したがって、通常のステレオとは異なり、広角魚眼画像では平面候補[24]をスイープしても、ステレオ対応を迅速に見つけることはできません。次に、魚眼画像上のエピソードラインは湾曲しており[39、50]、空間変動を伴うワープ対応探索が必要であり、計算コストが大幅に増加します。正距円筒図法または緯度経度投影法を使用して、直線のエピソード線を取得できます[52、34]。ただし、se-

vere image distortion, and a given disparity does not correspond to the same distance depending on its position in the image. Simply estimating the disparity in the equirectangular domain before converting to distance [32, 35] breaks the local disparity consistency assumption of cost aggregation. Lastly, we cannot merge multiview fisheye images as a 360° panorama image accurately without having a 360° *dense* distance map, and a clear 360° dense distance map cannot be filtered and obtained without a 360° panorama image. It is a chicken-and-egg problem when combining multiview fisheye images to a 360° RGB-D image with high accuracy.

In this work, we propose *real-time* sphere-sweeping stereo that can run directly on multiview fisheye images, without requiring additional spherical rectification using equirectangular or latitude-longitude projection by tackling three key points. First, we propose an adaptive spherical matching method that allows us to evaluate stereo matching directly on the fisheye image domain with consideration of the regional discrimination power of distance in each fish-eye image. Second, we introduce fast inter-scale cost volume filtering of optimal complexity $O(n)$ that allows for a stable sphere sweeping volume in noisy and textureless regions. It enables 360° *dense* distance estimation in all directions in real time while preserving edges. Lastly, colors at different distance maps are combined into a *complete* 360° panorama and distance map seamlessly through fast inpainting using the dense distance map.

We implemented our algorithm on a prototype made of an embedded computer with a mobile GPU and four fisheye cameras (Figure 1). Our prototype captures complete 360° RGB-D video that includes color and distance at every pixel with a resolution of two megapixels at 29 fps. Results validate that our real-time algorithm outperforms the traditional omnidirectional stereo and the learning-based 360° stereo algorithms in terms of accuracy and performance.

2. Related Work

Binocular Fisheye/360° Stereo. Two fisheye cameras [31, 32, 30, 13, 45, 46] or 360° cameras [2, 48, 35, 56] are placed on a baseline and then are used to estimate depth (more accurately distance in omnidirectional stereo) within the stereo field of view. Analogue to the traditional epipolar geometry, they apply spherical rectification and matching along the great circle. However, disparity in spherical stereo is proportional to the length of arc, which is not linearly proportional to the inverse of distance, hence requiring exhaustive correspondence search. An equirectangular or a latitude-longitude projection has been commonly used to rectify fisheye images before stereo matching [31, 32, 30, 35, 56, 28]. This process causes severe image distortion and disturbs correspondence search. Also, in this binocular setup, distance cannot be estimated properly along the baseline axis [35, 56], i.e., no complete 360°

panorama and distance maps can be computed directly from this binocular stereo setup due to occlusion between the cameras and, most importantly, due to the absence of exploitable baseline in the alignment. Our method uses just four cameras (same number as binocular 360° stereo methods [35, 56]) with fisheye lenses, but it can capture *complete* 360° RGB-D videos in real time. Note that methods that determine the relative position of the scene with planar depth estimation [22] are inherently limited to FoVs below 180°.

Monocular 360° Stereo. The traditional structure-from-motion algorithm has been applied to compact 360° imaging [7, 23, 42]. However, these methods assume that a 360° camera moves in static scenes. If these methods are applied to a scene with dynamic objects, their performances degrade rapidly. Also, computational costs of these methods are expensive, so they are inapplicable to *real-time* 360° RGB-D imaging. In addition, monocular stereo imaging has been applied to 360° panoramas by learning an omnidirectional image prior [62, 55]. Learned priors help matching correspondences in warped images. However, owing to the model complexity, no real-time learning-based method exists yet. Also, to date, there is no real-world dataset of omnidirectional RGB-D images available for deep learning. These methods have been trained on synthetically rendered images of hand-made 3D models and 3D scanning [8, 3, 54, 62, 59, 56, 28]. Owing to the domain gap between real and rendered images, these models often present suboptimal performance with unseen real-world data.

Multiview Fisheye Stereo. Multiple fisheye cameras have been combined to capture 360° RGB-D images with a number of cameras ranging from 4 to 20 [33, 1, 11, 6, 44]. When the camera count increases, the quality of color and distance images is improved significantly, but with rapid increase in hardware and computation cost. When combining multiview fisheye stereo images, technical challenges still exist hindering the real-time performance of this setup. First, for accounting for reprojection, occlusion and visibility of distance values in the unified omnidirectional image space, we need a complete 360° guide image, which cannot be obtained from multiview input without a dense 360° distance map. Only simple warp and blending methods were proposed without distance awareness [21, 20]. As they are designed for a short baseline, they often suffer from stitching artifacts when disparity changes in the overlapping regions. Second, due to the geometry of 360 matching, multiple true matches may occur. This has been handled by devising a computationally intensive cost aggregation [58, 26].

In contrast, we use the minimal number of fisheye cameras to cover *complete* 360° angles in real time so that we keep the manufacturing cost and computational requirement as low as possible. We propose an effective camera design and an adaptive spherical matching algorithm at multiple scales to handle the aforementioned challenges.

画像の歪みが非常に大きく、特定の視差は画像内の位置に応じて同じ距離に対応しません。距離に変換する前に正距円筒領域の格差を単純に推定すると [32, 35]、コスト集計の局所的な視差一貫性の仮定が破られます。最後に、360dense distance map がないと、マルチビュー魚眼画像を 360 パノラマ画像として正確にマージできず、360 panoramic image がないと、明確な 360dense 距離マップをフィルタリングして取得できません。マルチビュー魚眼画像を高精度で360RGB-D 画像に組み合わせる場合、鶏が先か卵が先かの問題です。

本研究では、3つの重要なポイントに取り組むことにより、正距円光法または緯度経度投影を用いた追加の球面補正を必要とせずに、マルチビュー魚眼画像上で直接実行できるリアルタイム球スイープステレオを提案します。まず、各魚眼画像における距離の地域識別力を考慮した上で、魚眼画像領域上で直接ステレオマッチングを評価できる適応球面マッチング法を提案する。次に、最適な複雑さ $O(n)$ の高速なスケール間コストボリュームフィルタリングを導入し、ノイズの多いテクスチャレス領域で安定した球スイープボリュームを可能にします。エッジを維持しながら、全方向の360 密な距離をリアルタイムで推定できます。最後に、さまざまな距離マップの色が、密集した距離マップを使用した高速インペインティングを通じて、完全な360パノラマおよび距離マップにシームレスに組み合わせられます。

このアルゴリズムは、モバイルGPUを搭載した組み込みコンピュータと4台の魚眼カメラで構成されたプロトタイプに実装しました(図 1)。私たちのプロトタイプは、29fpsで2メガピクセルの解像度で、すべてのピクセルで色と距離を含む完全な360 RGB-Dビデオをキャプチャします。その結果、当社のリアルタイムアルゴリズムは、精度とパフォーマンスの点で、従来の全方向性ステレオおよび学習ベースの360ステレオアルゴリズムよりも優れていることが実証されています。

2. 関連業務

双眼魚眼レンズ/ 360ステレオ。2台の魚眼カメラ[31、32、30、13、45、46]または360カメラ[2、48、35、56]をベースライン上に配置し、ステレオ視野内の深度(全方向ステレオでより正確に距離)を推定するために使用されます。従来のエピポーラ形状に類似して、大円に沿って球面整流とマッチングを適用します。ただし、球面ステレオの視差は円弧の長さに比例し、距離の逆数に線形に比例しないため、徹底的な対応探索が必要です。正距円筒図法または緯度経度投影法は、ステレオマッチングの前に魚眼画像を補正するために一般的に使用されてきました[31、32、30、35、56、28]。この処理により、画像の歪みが激しくなり、対応検索が妨げられます。また、この双眼鏡のセットアップでは、ベースライン軸[35、56]に沿って距離を適切に推定することはできません。

この双眼ステレオセットアップから完全な360 度パノラマおよび距離マップを直接計算することはできません。これは、カメラ間のオクルージョンと、最も重要なこととして、アライメントに利用可能なベースラインがないためです。私たちの方法では、魚眼レンズを備えた4台のカメラ(双眼 360ステレオ法[35、56]と同じ数)を使用しますが、リアルタイムで完全な360RGB-Dビデオをキャプチャできます。平面深度推定[22]を使用してシーンの相対位置を決定する方法は、本質的に180°未満のFoVに限定されることに注意してください。

単眼 360ステレオ。従来のstructure-from-motionアルゴリズムは、コンパクトな360 度イメージングに適用されています[7、23、42]。ただし、これらの方法では、360 度カメラが静的なシーンで移動することを前提としています。これらの方法をダイナミック オブジェクトを含むシーンに適用すると、パフォーマンスは急速に低下します。また、これらの手法の計算コストは高額であるため、リアルタイムの360 RGB-Dイメージングには適用できません。さらに、単眼ステレオイメージングは、事前に全方向性画像を学習することにより、360パノラマに適用されています[62、55]。学習された事前確率は、歪んだ画像内の対応を一致させるのに役立ちます。しかし、モデルが複雑なため、リアルタイム学習ベースの方法はまだ存在しません。また、これまでのところ、深層学習に利用できる全方向RGB-D 画像の実世界のデータセットはありません。これらの方法は、手作りの3Dモデルと3Dスキャンの合成レンダリング画像でトレーニングされています[8、3、54、62、59、56、28]。実際の画像とレンダリングされた画像の間には領域ギャップがあるため、これらのモデルは、目に見えない現実世界のデータでは最適ではないパフォーマンスを示すことがよくあります。

マルチビュー魚眼ステレオ。複数の魚眼カメラを組み合わせ、4 から 20 までの多数のカメラで 360RGB-D 画像をキャプチャしています [33、1、11、6、44]。カメラの数が増えると、カラー画像と距離画像の品質は大幅に向上しますが、ハードウェアと計算コストが急激に増加します。マルチビュー魚眼ステレオ画像を組み合わせる場合、このセットアップのリアルタイム性能を妨げる技術的な課題がまだ存在します。まず、統一された全方向性画像空間での距離値の再投影、オクルージョン、および可視性を考慮するために、完全な360 度ガイド画像が必要ですが、これは密集した360 度距離マップなしではマルチビュー入力から取得できません。単純な縦糸とブレンドの方法のみが、距離を意識せずに提案されました[21、20]。これらは短いベースライン用に設計されているため、重なり合う領域で視差が変化すると、ステッチアーティファクトが発生することがよくあります。次に、360 度マッチングのジオメトリにより、複数の真の一致が発生する可能性があります。これは、計算集約的なコスト集約を考案することによって処理されてきました[58、26]。

対照的に、最小限の数の魚眼カメラを使用して、リアルタイムで完全な360 度角度をカバーするため、製造コストと計算要件を可能な限り低く抑えています。私たちは、前述の課題に対処するために、効果的なカメラ設計と複数のスケールでの適応性のある球面マッチングアルゴリズムを提案します。

3. Fast Sphere Sweeping Stereo

Hardware Design. Our hardware setup employs a minimum number of cameras to achieve a 360° RGB-D image, i.e., four cameras with fisheye lenses. Each fisheye camera has the field of view of 220°. A pair of front-backward fish-eye cameras is placed on the top, and another pair of fisheye cameras is placed on the bottom but in a perpendicular direction (Figure 1), so that each combination of neighboring stereo pairs has the same baseline.

Spherical Geometry. We base our work on the classical binocular stereo model [30]. Each pixel in the reference frame I_{c_0} captured by reference camera c_0 describes the perceived color of a ray at angle of polar coordinates (θ, ϕ) . It corresponds to the point of polar coordinates (θ, ϕ, d) , where d is a distance. This leads to the following 3D position p in c_0 's space: $p = d [\sin(\theta) \cos(\phi), \sin(\theta) \sin(\phi), \cos(\theta)]^T$.

Suppose another camera c_1 at rotation R_{c_1} and position T_{c_1} w.r.t. the reference camera c_0 . The camera captures the images I_{c_0} and I_{c_1} . Position p in c_1 's space is: $p_{c_1} = R_{c_1}^{-1}(p - T_{c_1})$. Let $\hat{p}_{c_1} = p_{c_1}/\|p_{c_1}\|$ be the normalized vector of p_{c_1} , which is the pixel coordinates in I_{c_1} : $(\theta_{c_1}, \phi_{c_1}) = (\arccos(\hat{p}_{c_1} z), \frac{3\pi}{2} - \arctan2(\hat{p}_{c_1} y, \hat{p}_{c_1} x))$. The pixel coordinates in c_1 with camera transformation $R_{c_1}|T_{c_1}$ can be expressed as the projection of pixel of angle (θ, ϕ) at distance d in the reference coordinate system: $(\theta_{c_1}, \phi_{c_1}) = \bar{P}_{R_{c_1}|T_{c_1}}(\theta, \phi, d)$. Assuming Lambertian surfaces in a scene, a pixel $I_{c_1}(\theta_{c_1}, \phi_{c_1})$ of camera c_1 's image is the same as $I_{c_0}(\theta, \phi)$ in the reference camera. Pixels in other cameras' images can be expressed w.r.t. the reference coordinate system in the same way.

Sphere Sweep Volume. Similarly to multi-view stereo with standard camera model, we build a sweep volume for several distance candidates $d_0, \dots, d_{N-1}$. Instead of warping I_{c_1} to I_{c_0} following homographies with planar distance candidates [24], we use the previously described mapping and spheres distance candidates around the reference frame or a given point [59].

For each candidate, we create a warped version of I_{c_1} that can be matched to I_{c_0} if the distance candidate is correct. In details, for all pixels coordinates (θ, ϕ) in I and for all distance candidate d_i , we find the corresponding coordinates. This process is depicted in Figure 2. We then assign the values of the sphere sweep volume V as follows: $V_{c_1 \rightarrow c_0}(\theta, \phi, i) = I_{c_1}(\bar{P}_{R_{c_1}|T_{c_1}}(\theta, \phi, d_i))$. In this volume, a correct distance candidate d_k shows good matching: $V_{c_1 \rightarrow c_0}(\theta, \phi, k) \approx I_{c_0}(\theta, \phi)$, which provides a direct cue for distance estimation. The quality of matching can be evaluated through photometric difference or difference after image transformation: gradient [17], census transform [29] or feature extraction [59]. For robust performance, cost aggregation [19, 18, 61] or deep regularization [57] is neces-




Figure 2: Projection in the sphere sweep volume. A pixel of coordinates (θ, ϕ) in camera c_0 has different coordinates in c_1 depending on the scene's distance: the red and the blue points correspond to pixel positions for two extreme distances. Circles red and blue represent the closest and furthest distance candidates around c_0 while the dotted ones are intermediate candidates in the sweeping volume.

sary when selecting the best depth candidate. Several views can also be used simultaneously [24].

3.1. Adaptive Spherical Matching

In theory, we can evaluate entire depth candidates in all possible combinations of overlapped regions along the baseline in the sphere sweeping volume. It is exhaustive computation. For achieving real-time performance, we tailor a camera selection method that provides the regional best camera pairs for search correspondence in the sphere sweeping volume w.r.t. the reference camera.

We select only the best camera among other three cameras (c_1 , c_2 and c_3) for each pixel in the reference view. If several cameras have a field of view that covers a pixel in the reference frame, we select the one that has the highest distance discriminating power. This property can be described as maximizing the difference between the layers of the sphere sweep volume and be able to identify which candidate matches the best more clearly.

To quantify this for a given pixel position (θ, ϕ) in the reference image I_{c_0} , we focus on the first and last layers 0 and $N-1$ of the volume, corresponding to the distance candidates d_0 and d_{N-1} . Let $p_{c_k}^{<i>}$ be the point in camera c_k 's space of reference coordinates (θ, ϕ, d_i) . The best camera c_k is the one that shows the most angular change between two 3D points $p_{c_k}^{<0>}$ and $p_{c_k}^{<N-1>}$ given from these two distance candidates.

In detail, if the angle between $p_{c_k}^{<0>}$ and $p_{c_k}^{<N-1>}$ is high, the sampled location in the selected camera for the sweeping volume will change significantly, which is suitable for distance estimation. We define the discriminating power weight based on those considerations: $q_{c_k} = |\arccos \langle \hat{p}_{c_k}^{<0>} \cdot \hat{p}_{c_k}^{<N-1>} \rangle|$, with $\hat{p} = p/\|p\|$ are normalized vectors. Using this evaluation, we select the optimal camera c^* for each pixel in the reference following:

$$c^*(\theta, \phi) = \underset{c_k}{\operatorname{argmax}}(q_{c_k}). \quad (1)$$

3.ファストスフィアスイーピングステレオ

ハードウェア設計。当社のハードウェアセットアップでは、360RGB-D 画像を実現するために最小限の数のカメラ、つまり魚眼レンズを備えた4 台のカメラを採用しています。各魚眼カメラの視野は 220 です。一对の前後の魚眼カメラが上部に配置され、別の一对の魚眼カメラが下部に垂直方向に配置され(図 1)、隣接するステレオペアの各組み合わせのベースラインが同じになるようにします。

球面ジオメトリ。私たちは、古典的な双眼ステレオモデル [30]に基づいて作業を行います。参照カメラによってキャプチャされた参照フレーム内の各ピクセルは、極座標の角度(θ , ϕ)で光線が知覚する色を表します。これは極座標(θ , ϕ , d)の点に対応し、 d は距離です。これにより、 c の空間内の p の 3D 位置 p が得られます: $p = d$

$$\begin{bmatrix} \sin(\theta) \cos(\phi), \sin(\theta) \sin(\phi), \cos(\theta) \end{bmatrix}.$$

別のカメラ c へ回転 R 位置 T w.r.t. が参照カメラ c であると仮定します。カメラは画像 I and I_c 空間内の位置 p は $p = R_c(p - T)$ です。 $\hat{p} = p / \|p\|$ を p の正規化ベクトルとし、これは I のピクセル座標です: $(\theta, \phi) =$

$$\left(\arccos(\hat{p}_z), -\arctan2(\hat{p}_y, \hat{p}_x) \right).$$

c with カメラ変換 $R|T$ は、基準座標系の距離 d における角度(θ , ϕ)のピクセルの投影として表すことができます: $(\theta, \phi) = P(\theta, \phi, d)$ 。シーン内のランバート曲面を仮定すると、カメラ c のイメージのピクセル $I_c(\theta, \phi)$ は、参照カメラの $I(\theta, \phi)$ と同じです。他のカメラの画像のピクセルは、同じように基準座標系で表現できます。

Sphere Sweep Volume (球スイープ ボリューム)。標準カメラモデルを使用したマルチビューステレオと同様に、いくつかの距離候補 $d_1, \dots, d_N$ のスイープボリュームを構築します。平面距離の候補 [24]で伊藤 Ifollowingの同形異義語を歪める代わりに、前述のマッピングと参照フレームまたは特定の点の周りの球距離の候補を使用します [59]。

各候補について、距離の候補が正しい場合に I_c に一致させることができる I の歪んだバージョンを作成します。詳細には、 I のすべてのピクセル座標(θ , ϕ)とすべての距離候補 d について、対応する座標を見つけます。このプロセスを図 2 に示します。次に、球スイープボリューム V の値を次のように割り当てます: $V(\theta, \phi, i) = I(P(\theta, \phi, d_i))$ 。このボリュームでは、正しい距離の候補 d は、 $V(\theta, \phi, k) \approx I(\theta, \phi)$ という良好なマッチングを示しており、これは距離推定の直接的な手がかりを提供します。マッチングの品質は、測光差または画像変換後の違い(グラデーション [17]、国勢調査変換 [29]、または特徴抽出 [59])を通じて評価できます。ロバストなパフォーマンスを実現するには、コスト集計 [19、18、61] または深い正則化 [57] が必要です。




図 2:球スイープボリュームでの投影。カメラ内の座標 (θ , ϕ) のピクセルは、シーンの距離に応じて異なる座標を持ちます: 赤と青の点は、2つの極端な距離のピクセル位置に対応します。赤と青の円は、 c の周りの最も近い距離と最も遠い距離の候補を表し、点線の円はスイープボリュームの中間候補です。

最適な深さの候補を選択するときは、sary。複数のビューを同時に使用することもできます [24]。

3.1. 適応球面マッチング 理論的には、球スイープボリュームのベースラインに沿ったオーバーラップ領域のすべての可能な組み合わせで、全深度候補を評価できます。これは網羅的な計算です。リアルタイムパフォーマンスを実現するために、参照カメラを使用した球スイープボリュームでの検索対応に地域的な最適なカメラペアを提供するカメラ選択方法を調整します。

参照ビューの各ピクセルについて、他の3つのカメラ(c , c_{and} , c)の中から最適なカメラのみを選択します。複数のカメラが参照フレームのピクセルをカバーする視野を持っている場合、距離識別力が最も高いカメラを選択します。このプロパティは、球スイープボリュームのレイヤー間の差を最大化し、どの候補が最適に一致するかをより明確に識別できるようにすると説明できます。

参照画像 I の特定のピクセル位置(θ , ϕ)についてこれを定量化するために、距離候補 d と d に対応するボリュームの最初と最後のレイヤー 0 と $N - 1$ に焦点を当てます。 p_c をカメラ c の参照座標の空間内の点(θ , ϕ , d)とします。最高のカメラは、これらの2つの距離候補から与えられた2つの 3D ポイント p_c と p_c の間の最も角度の変化を示すカメラです。

詳細には、 p_c と p_c の間の角度が大きい場合、スイープボリュームに対して選択したカメラでサンプリングされた位置が大幅に変化するため、距離推定に適しています。これらの考慮事項に基づいて判別力の重みを定義します: $q = \|\hat{p} - \hat{p}_c\|$

$\hat{p}$ 、 $\hat{p}_c = \frac{p}{\|p\|}$ 、 $\hat{p}_c = \frac{p_c}{\|p_c\|}$ は正規化されたベクトルです。この評価を使用して、次の参照の各ピクセルに最適なカメラ c を選択します。

$$c(\theta, \phi) = \underset{c}{\operatorname{argmax}} \quad (q) \text{ です。} \tag{1}$$




Figure 3: (a) We evaluate how a ray in c_0 is reprojected in c_1 and c_2 . For this pixel, the best camera for matching is the one that shows the maximum displacement for a given distance: if a small change of distance leads to a high displacement, the distance discriminating power is improved. (a) shows that, for this specific ray in c_0 , c_1 is a better camera for matching than c_2 , despite the baseline between both pairs being similar. (b) For each pixel in c_0 , the camera showing the best distance discrimination is selected. Note that (a) shows a hypothetical layout for visualization.

Figure 3 shows an example of camera selection for a given ray angle in the reference frame and a map of which camera is selected depending on the pixel position.

3.2. Efficient Spherical Cost Aggregation

Once we built the prototype, we calibrated the four cameras using the double sphere model [53]. We perform two 220° distance estimation using the two opposed top cameras as two references. For each pixel in each reference, we select the best camera using our selective matching. Let I_{c_s} be the image from the camera selected at pixel (θ, ϕ) and I_{c_0} be the reference frame. The matching cost for the i th distance candidate is: $C(\theta, \phi, i) = \|V_{c_s \rightarrow c_0}(\theta, \phi, i) - I(\theta, \phi)\|_1$, where $V_{c_s \rightarrow c_0}$ is the sphere sweeping volume from the selected camera to the reference one. We then regularize each slice of the spherical cost volume using our fast filtering method described in the following section. After cost volume filtering, the optimal distance is voted via winner-takes-all, and sub-candidate accuracy is achieved through quadratic fitting.

3.2.1 Fast Inter-Scale Bilateral Filtering

For aggregating sparse distance to obtain a dense distance map, there are many available methods that smooth costs in an edge-aware manner. Bilateral grid-based methods [4, 10], while showing impressive capabilities, are still computationally expensive to be applied on the 3D cost volume and often produce blocky artifacts even with domain transform post processing [14]. A more hardware-friendly




Figure 4: Inter-scale bilateral filtering. We first downsample with edge preservation using the bilateral weights between the guidance center and the neighbor pixels to aggregate sparse costs. Then, we upsample using a minimal pixel support. We use guidance weights computed between the guidance centers and the pixels to aggregate at lower scale.

version of the fast bilateral solver has been devised [36]. While having demonstrated strong performance for a single depth map, it is more hardware specific and is still not computationally efficient enough to be applied to a complete cost volume in real time. Another popular edge-aware filtering is the guided filter [16, 15], which has been used with cost volume pyramids [43] or multi-scale cost aggregation [61]. While showing optimal complexity of $O(n)$, they cannot perform fast on GPU because they suffer from computation overhead when computing integral images in parallel environments. To achieve two megapixels real-time RGB-D imaging at 29 fps on an embedded machine with a GPU, we introduce a fast inter-scale bilateral filtering method specially designed for parallel computing environments.

Edge-Preserving Downsampling. The first step of our filtering is to downscale input image without blurring, thus preventing edge bleeding and halos. To this end, we perform filtering with the neighbor pixels with bilateral weights before decimation. We define I_0 the original image and I_l image after being downsampled by two l times. We first define bilateral weights:

$$w_{mn}^\downarrow(I, x, y) = \exp\left(-\frac{\|I(x, y) - I(x + m, y + n)\|^2}{2\sigma_I^2}\right), \quad (2)$$

where σ_I is the edge preservation parameter, and (x, y) are pixel coordinates. We define the downsampling scheme as:

$$I_l^\downarrow(x, y) = \sum_{m,n=-1}^1 I(2x + m, 2y + n) w_{mn}^\downarrow(I, 2x, 2y) / \tau, \quad (3)$$

where τ is the normalizing constant. In the pyramid, we note $I_{l+1} = I_l^\downarrow$. We define the number of scale levels L .

Edge-Preserving Upsampling. Unlike existing edge-preserving upsampling methods [27, 9] that use the high resolution image as guide, our method uses the bilateral weights between the downsampled and the full resolution image to achieve optimal complexity. Note that we intentionally do not use Gaussian spatial weights proposed by Kopf et al. [27] to focus on efficiency, and as they are designed for a wider support.

In addition to bilateral weights, we blend the scales using a Gaussian function of the current scale index. They are




図 3:(a)cisの光線がcand cでどのように再投影されたかを評価します。このピクセルの場合、マッチングに最適なカメラは、特定の距離の最大変位を示すカメラです:距離の小さな変化が大きな変位につながる場合、距離識別力が向上します。(a)は、Cのこの特定の光線について、両方のペア間の基線が類似しているにもかかわらず、cisがcよりもマッチングに適したカメラであることを示しています。(b)cの各ピクセルについて、最適な距離識別を示すカメラが選択されます。(a)は、視覚化のための架空のレイアウトを示していることに注意してください。

図 3 は、参照フレーム内の特定の光線角度に対するカメラ選択の例と、ピクセル位置に応じて選択されるカメラのマップを示しています。

3.2. 効率的な球面コスト集約 プロトタイプを構築した後、ダブルスフィアモデルを使用して4台のカメラをキャリブレーションしました[53]。対向する2台のトップカメラを2つの基準として使用して、2つの220 距離推定を実行します。各参照の各ピクセルについて、選択的マッチングを使用して最適なカメラを選択します。ピクセル(θ , ϕ)で選択したカメラからの画像をIbe、参照フレームをIbeとします。idistance 候補のマッチングコストは、 $C(\theta, \phi, i) = \|V(\theta, \phi, i) - I(\theta, \phi)\|$ です。ここで、Vis は選択したカメラから参照カメラまでの球スイープ ボリュームです。次に、次のセクションで説明する高速フィルタリング方法を使用して、球状コストボリュームの各スライスを実行します。コスト ボリュームのフィルタリング後、最適な距離は winnertakes-all によって投票され、サブ候補の精度は2 次フィッティングによって達成されます。

3.2.1 高速インタースケールバイラテラルフィルタリング

疎な距離を集約して密な距離マップを取得するために、エッジ対応の方法でコストを平滑化する多くの方法があります。バイラテラルグリッドベースの方法[4, 10]は、優れた機能を示していますが、3Dコストボリュームに適用するには依然として計算コストが高く、ドメイン変換の後処理[14]でもブロック状のアーティファクトを生成することがよくあります。よりハードウェアに優しい




図 4:スケール間のバイラテラルフィルタリング。まず、ガイダンスセンターと隣接ピクセルの間の両側の重みを使用してエッジ保持でダウンサンプリングし、スパースコストを集計します。次に、最小限のピクセルサポートを使用してアップサンプリングします。ガイダンスセンターとピクセルの間で計算されたガイダンスウェイトを使用して、より低いスケールで集約します。

高速バイラテラルソルバーのバージョンが考案されました[36]。単一の深度マップで強力なパフォーマンスが実証されていますが、ハードウェア固有であり、完全なコスト ボリュームにリアルタイムで適用できるほど計算効率が十分ではありません。もう1つの一般的なエッジ対応フィルタリングは、ガイド付きフィルター [16, 15] で、コスト ボリューム ピラミッド [43] またはマルチスケール コスト集計 [61] で使用されています。O(n) の最適な複雑さを示していますが、並列環境で積分イメージを計算するときに計算オーバーヘッドが発生するため、GPU では高速に実行できません。GPUを搭載した組み込みマシンで29fpsで2メガピクセルのリアルタイムRGB-Dイメージングを実現するために、並列コンピューティング環境向けに特別に設計された高速なインタースケールバイラテラルフィルタリング方式を導入します。

エッジ保持ダウンサンプリング。フィルタリングの最初のステップは、入力画像をぼかさに縮小し、エッジのにじみやハローを防ぐことです。この目的のために、デシメーションの前に両側の重みを持つ隣接ピクセルでフィルタリングを実行します。元の画像とIimageを2 l 倍ダウンサンプリングした後で定義します。まず、二国間の重みを定義します。

$$w(l, x, y) = \exp \left(-\frac{\|I(x, y) - I(x + m, y + n)\|^2}{2\sigma} \right), \quad (2)$$

ここで、 σ はエッジ保持パラメータ、 (x, y) はピクセル座標です。ダウンサンプリング スキームを次のように定義します。

$$I(x, y) = \sum_{m,n=-1}^1 I(2x + m, 2y + n)w(l, 2x, 2y)/\tau, \quad (3)$$

ここで、 τ は正規化定数です。ピラミッドでは、 $I = I$ と表記します。スケールレベルLの数を定義します。

エッジ保持アップサンプリング。高解像度画像をガイドとして使用する既存のエッジ保持アップサンプリング方法 [27, 9]とは異なり、私たちの方法では、ダウンサンプリングされた画像とフル解像度の画像との間の両側の重みを使用して、最適な複雑さを実現します。Kopf et al. [27] によって提案されたガウス空間ウェイトは、効率に焦点を当てるために意図的に使用せず、より広範なサポートのために設計されていることに注意してください。

二国間の重みに加えて、現在のスケールインデックスのガウス関数を使用してスケールをブレンドします。彼らです




Figure 5: Impact of the filter kernel with different edge preservation parameters. Our method yields high preservation and smoothing capabilities with global support while showing minimal runtime.

defined for each scale as $w_l^\uparrow = \exp\left(\frac{(2^l)^2}{2\sigma_s^2}\right)$, where σ_s is the smoothness parameter. The weight for the higher resolution scale is naturally $1 - w_l^\uparrow$. Figure 4 depicts our multi-scale filtering process.

Filter Kernel. The final filter kernel obtained after this downsampling/upsampling process yields smooth fall off driven by σ_s as we move away from the center and does not cross edge boundaries as shown in an example in Figure 5. Although the each step of the algorithm only covers a minimal pixel support, the bilateral downsampling/upsampling filtering yields a kernel that covers the *entire* image. The guidance through the bilateral weights is a composition of exponential with a higher order far from a given pixel. This naturally provides increased guidance between spaced pixels. For our results, σ_s is set to 25, and σ_I is set to 10.

Complexity. The number of operations follows the sum of a geometric series with ratio $\frac{1}{4}$. The asymptotic complexity is therefore $O(n)$ with n the number of pixels, making the algorithm optimal. The number of levels has to allow the lowest level L to have a size above one pixel. We therefore downsample at most $\ln_4(n)$ times. While the downsampling and upsampling have to be run sequentially with $O(\ln(n))$ levels, each downsampling and upsampling steps are fully parallelized.

3.3. Distance-aware Panorama Stitching

Instead of estimating distance at the center, our distance estimation algorithm relies on reference frames for edge preservation and to avoid multiple true matches (Figure 6). While this approach yields an increased accuracy, an extra step is required to merge the fisheye images. We present an efficient method that first synthesizes a distance map at a desired location, then project the image following the 3D coordinates and finally merges the images through a blending process giving more weight to the least displaced pixels.

Novel View Synthesis. The first step is to reproject the dense distance maps to a selected location, common to both references. To this end, we find for each pixel (θ, ϕ) its corresponding position, and translate them to the selected loca-

tion and find the coordinates (θ_r, ϕ_r) in the reprojected image. We obtain: $(\theta_r, \phi_r) = \bar{P}_{T^*}(\theta, \phi, \hat{D}(\theta, \phi))$, where T^* is the desired position with respect to the camera and $\hat{D}$ is the estimated distance map.

This forward warping operation leads inevitably to multiple pixels in the original distance map mapping to the same target pixel, i.e., several couples (θ, ϕ) may be projected to the same coordinates (θ_r, ϕ_r) . This ambiguity requires splatting to obtain the final value.

We merge the possible pixels in an occlusion aware manner following [40]. Specifically, we use minimum distance splatting, i.e., z-buffering, hence the reprojected distance:

$$\begin{aligned} \hat{D}_r(\theta_r, \phi_r) &= \min \hat{D}(\theta, \phi), \\ \text{s.t. } \bar{P}_{T^*}(\theta, \phi, \hat{D}(\theta, \phi)) &= (\theta_r, \phi_r). \end{aligned} \quad (4)$$

Directional Inpainting. While some pixels in the target can have several counterparts in the original distance map, some pixels have none due to occlusion. We inpaint the missing regions using the background as they can be occluded by the foreground objects. To this end, we first determine the background-to-foreground direction. This is given by the derivative of the projection w.r.t. the distance. Indeed, occlusion holes in the reprojected map are caused by areas with different distance not being reprojected at the same location. We therefore define the inpainting direction: $v_{T^*}(\theta, \phi) = \frac{\partial \bar{P}_{T^*}(\theta, \phi, d)}{\partial d}$. This inpainting direction leads to a directed diffusion kernel that can be used iteratively as proposed by [41]. We determine kernel weights around each pixel depending on their similarity with the inpainting direction: $w_{m,n} = \langle v_{T^*}(\theta, \phi) \cdot (m, n) \rangle^+$, where $^+$ is the positive part and $(m, n) \in \llbracket -1, 1 \rrbracket^2 \setminus (0, 0)$ are the indices of the eight neighbor pixels. As the dot product gives high weights for aligned vectors, this method naturally creates a diffusion kernel that uses the values of the pixels aligned with the inpainting direction (Figure 8).

Once the distance is moved to the given point of view, we simply project the color pixel following the 3D coordinates given in the distance map, providing the RGB image at a different location.

Blending. After projecting color images to a common location, the two 220° images need to be merged together to create a complete panorama stored in the standard equirectangular projection. To that end, we provide blending weights that correspond to the amount of possible occlu-




Figure 6: A ray from O crosses multiple objects that are seen from both cameras, meaning that several depth candidates have true matches. We instead stitch fisheye images using depth maps.




図 5:エッジ保持パラメータが異なるフィルターカーネルの影響。私たちの方法は、最小限のランタイムを示しながら、グローバルサポートにより高い保存機能と平滑化機能を実現します。

各スケールは、 $w = \exp(-\frac{d}{\sigma})$ として定義され、高解像度スケールの重量は、当然ながら $1 - w$ です。図 4は、マルチスケールフィルタリングプロセスを示しています。カーネルをフィルタリングします。このダウンサンプリング/アップサンプリング プロセス後に得られる最終的なフィルターカーネルは、図 5 の例に示すように、中心から離れてエッジ境界を越えないため、 σ によって駆動されるスムーズなフォールオフが得られます。アルゴリズムの各ステップは最小限のピクセルサポートのみをカバーしますが、バイラテラルダウンサンプリング/アップサンプリングフィルタリングにより、画像全体をカバーするカーネルが得られます。両側の重みによるガイダンスは、特定のピクセルから遠く離れた高次数の指数関数の構成です。これにより、間隔を空けたピクセル間のガイダンスが自然に増加します。私たちの結果では、 σ は25に設定され、 σ は10に設定されています。

複雑さ。演算の数は、比を持つ等比級数の合計に従います。したがって、漸近的な複雑さは $O(n)$ で n はピクセル数であり、アルゴリズムは最適です。レベルの数は、最も低いレベルの L が1ピクセルを超えるサイズを持つことができるようにする必要があります。したがって、最大 $\ln(n)$ 回でダウンサンプリングします。ダウンサンプリングとアップサンプリングは $O(\ln(n))$ レベルで順番に実行する必要がありますが、各ダウンサンプリングとアップサンプリングのステップは完全に並列化されています。

3.3. 距離を意識したパノラマスティッチング 中心での距離を推定する代わりに、距離推定アルゴリズムは、エッジを保持し、複数の真の一致を回避するために参照フレームに依存しています(図 6)。このアプローチでは精度が向上しますが、魚眼画像をマージするには追加の手順が必要です。最初に目的の場所で距離マップを合成し、次に3D 座標に従って画像を投影し、最後にブレンディングプロセスを通じて画像をマージし、最も変位の少ないピクセルにより多くの重みを与える効率的な方法を紹介します。

斬新なビュー合成。最初のステップは、密集した距離マップを選択した位置 (両方の参照に共通) に再投影することです。この目的のために、各ピクセル (θ, ϕ) に対応する位置を見つけます

を選択し、それらを選択した位置に変換し、再投影された画像内の座標 (θ, ϕ) を見つけます。 $(\theta, \phi) = P(\theta, \phi, \hat{D}(\theta, \phi))$ を求めます。ここで、 T はカメラに対する所望の位置、推定距離マップ。このフォワードワープ操作は、必然的に元の距離マップの複数のピクセルを同じターゲットピクセルにマッピングすること、つまり、いくつかのカップル (θ, ϕ) が同じ座標 (θ, ϕ) に投影される可能性があります。このあいまいさにより、最終的な値を取得するにはスプラッティングが必要です。

可能なピクセルを[40]に従ってオクルージョンを考慮した方法でマージします。具体的には、最小距離スプラッティング、つまり z バッファリングを使用するため、再投影された距離が得られます。

$$\hat{D}(\theta, \phi) = \min \hat{D}(\theta, \phi), \quad (4)$$

$$\text{s.t. } P(\theta, \phi, \hat{D}(\theta, \phi)) = (\theta, \phi).$$

指向性インペインティング。ターゲット内の一部のピクセルは、元の距離マップに複数の対応するものを持つことができますが、オクルージョンのために何も持たないピクセルもあります。欠落している領域は、前景のオブジェクトによって遮られる可能性があるため、背景を使用してインペイントします。この目的のために、まず背景から前景への方向を決定します。これは、距離の投影法 w.r.t. の導関数によって与えられます。実際、再投影されたマップのオクルージョンホールは、距離の異なるエリアが同じ場所に再投影されないために発生します。したがって、修復方向を定義します: $v(\theta, \phi) = \partial d$ 。このインペインティング方向は、[41]で提案されているように反復的に使用できる指向性拡散カーネルにつながります。各ピクセルの周りのカーネルの重みは、インペインティング方向との類似性に依拠して決定します: $w = \langle v(\theta, \phi) \cdot (m, n) \rangle$ 、ここでは正の部分、 $(m, n) \in [[-1, 1]] \setminus (0, 0)$ は8つの隣接ピクセルのインデックスです。ドット積は整列したベクトルに対して高い重みを与えるため、この方法では、インペインティング方向に整列したピクセルの値を使用する拡散カーネルが自然に作成されます(図 8)。

距離が指定された視点に移動すると、距離マップで指定された3D 座標に従ってカラーピクセルを投影するだけで、RGB 画像が別の場所に表示されます。

ブレンド。カラー画像を共通の場所に投影した後、2つの220画像を結合して、標準の正距円筒図法に保存された完全なパノラマを作成する必要があります。そのために、可能な閉塞の量に対応するブレンディングウェイトを提供します。




図 6: O からの光線は、両方のカメラから見える複数の物体を横切るため、複数の深度候補が真に一致することを意味します。代わりに、深度マップを使用して魚眼画像をステッチします。




Figure 7: Real results captured with our prototype. Refer to the supplemental video for real-time demo of our prototype.




Figure 8: Depth at the camera position (a) is projected to the desired view in a depth-aware manner (b). As occlusion generates holes in the projected distance map, we compute an inpainting kernel (c) depending on the occlusion direction. We finally apply this inpainting kernel to the distance map to remove holes using the background depth values (d).

sion. In pixels where $v_{T^*}(\theta, \phi)$ is large, distance changes can modify the image greatly, introducing wider occluded regions, more distance related distortion and potential artifacts. We therefore define the blending weights following a Gaussian on the length of this vector: $b_{c_k}(\theta, \phi) = \exp\left(-\frac{\|v_{T^*}(\theta, \phi)\|_2^2}{2\sigma^2}\right)$. Note that we handle the pixels that cannot be captured by the camera by setting $b_{c_k}(\theta, \phi) = 0$. We estimate the derivatives through finite difference over the distance range.

4. Results

Prototype. We install four cameras using Sony IMX477 sensors on an NVIDIA Jetson Xavier embedded computer with a mobile GPU. The cameras look at four different directions to have both horizontal and vertical baselines (6.8 cm), see Figure 1. We capture and process four fish-eye frames of 1216×1216 px and output 2048×1024 px distance maps and panoramas. Two reference frames’s resolution is 1024×1024 px. We therefore process a total of 2.1 Mpx. For our tests, we used 32 distance candidates with a $[0.55, 100]$ m range. On the NVIDIA Jetson Xavier, our algorithm computes a RGB-D frame within 34 ms in total, including: cost computation: 14 ms, cost regularization:

10 ms, distance selection and sub-candidate interpolation: 3 ms, and reprojection and stitching: 7 ms. For experiments on a desktop computer, we use an AMD Ryzen Threadripper 3960X with an NVIDIA GTX 1080 Ti. Figure 7 shows results.

Dependency on the camera rig. Our method can be generalized to other rig layouts without modification as long as two cameras cover the entire field of view for stitching. It is also possible to use and stitch more than two references with the same methodology in case no couple of cameras covers the entire field of view. In addition, when using more than four cameras, our adaptive matching will not be prone to a significant change in performance or accuracy.

Synthetic Dataset. To evaluate a wider variety of camera setups with ground truth panorama and distance maps, we build our own rendered dataset. We render 95 frames at random locations with ten different scenes, collected from McGuire computer graphics archive [37] and the official Blender website [49]. Each frame is composed of four fish-eye images with 220° FoV. We follow positions and rotation shown in OmniHouse [58] for fair comparison with learning-based methods trained on this dataset, with scaling to match our prototype’s form factor. In addition, we render the ground truth RGB panorama and distance maps at the center of the rig as equirectangular images and an additional equirectangular RGB panorama at 7.5 cm to create a stereo pair and evaluate spherical binocular stereo methods. We constrain a minimum distance between the camera rig and the scene of 0.55 m to ensure a distance map within the range of all methods.

Metric. We evaluate the distance quality in its inverse domain on equirectangular images. We define the distance error for one pixel as:

$$E(\theta, \phi) = \left| \frac{1}{\hat{D}(\theta, \phi)} - \frac{1}{D^*(\theta, \phi)} \right|, \quad (5)$$

where $\hat{D}$ is the estimated distance and D^* is the ground



図 7: プロトタイプでキャプチャされた実際の結果。プロトタイプのリアルタイムデモについては、補足ビデオを参照してください。




図 8: カメラ位置の深度(a)は、深度を認識した方法で目的のビューに投影されます(b)。オクルージョンは投影距離マップに穴を生成するため、オクルージョン方向に応じてインペインティングカーネル(c)を計算します。最後に、この修復カーネルを距離マップに適用し、背景の深度値 (d) を使用して穴を削除します。

シオン。 $v(\theta, \phi)$ が大きいピクセルでは、距離の変化によって画像が大きく変化し、オクルード領域が広くなり、距離に関連する歪みや潜在的なアーティファクトが発生する可能性があります。したがって、このベクトルの長さに対するガウス分布に続くブレンディング重みを定義します:

$$b(\theta, \phi) = \exp\left(-\frac{v(\theta, \phi)}{\sigma}\right)$$

カメラでキャプチャできないピクセルは、 $b(\theta, \phi) = 0$ を設定して処理することに注意してください。距離範囲にわたる有限差によって微分を推定します。

4. 結果

原型。Sony IMX477センサーを使用して、モバイルGPUを搭載したNVIDIA Jetson Xavier 組み込みコンピューターに4台のカメラを取り付けます。カメラは、水平方向と垂直方向の両方のベースライン(6.8 cm)を持つために4つの異なる方向を見ます(図 1を参照)。1216×1216pxの4つの魚眼フレームをキャプチャして処理し、2048×1024pxの距離マップとパノラマを出力します。2つの参照フレームの解像度は1024×1024 px です。したがって、合計 2.1 Mpx を処理します。私たちのテストでは、[0.55, 100]mの範囲で32の距離候補を使用しました。NVIDIA Jetson Xavier では、アルゴリズムは合計 34 ミリ秒以内に RGB-D フレームを計算します。これには、コスト計算: 14 ミリ秒が含まれます

コストの正則化:10ミリ秒、距離選択とサブ候補の補間:3ミリ秒、再投影とスティッチング:7ミリ秒。デスクトップコンピュータでの実験には、AMD Ryzen Threadripper 3960XとNVIDIA GTX 1080 Tiを使用しました。図 7に結果を示します。

カメラリグへの依存。この方法は、2台のカメラがスティッチングのために視野全体をカバーしている限り、変更せずに他のリグレイアウトに一般化できます。また、2台以上のカメラが視野全体をカバーしない場合に備えて、同じ方法で2つ以上のリファレンスを使用してステッチすることも可能です。さらに、4台以上のカメラを使用する場合、アダプティブマッチングはパフォーマンスや精度に大きな変化をもたらすことはありません。

合成データセット。グラウンドトゥルース、パノラマ、距離マップを使用してさまざまなカメラ設定を評価するために、独自のレンダリングデータセットを構築します。

McGuire コンピュータ グラフィックス アーカイブ [37] と Blender の公式 Web サイト [49] から収集した 10 の異なるシーンで、ランダムな位置で 95 フレームをレンダリングします。各フレームは、220FoV の4つの魚眼画像で構成されています。OmniHouse [58] に示されている位置と回転に従って、このデータセットでトレーニングされた学習ベースの方法と公平に比較し、プロトタイプのフォームファクターに一致するようにスケーリングします。さらに、リグの中央にあるグラウンドトゥルース RGB パノラマと距離マップを正距円筒イメージとしてレンダリングし、7.5 cm の正距円筒 RGB パノラマを追加してステレオペアを作成し、球面両眼ステレオ法を評価します。カメラリグとシーンの間の最小距離を0.55mに制限して、距離マップがすべての方法の範囲内にあることを確認します。

メトリック。距離の品質を正距円筒図法の画像で逆領域で評価します。1つのピクセルの距離誤差を次のように定義します。

$$E(\theta, \phi) = \frac{|\hat{D} - D|}{\hat{D}}, \quad (5)$$

ここで、 $\hat{D}$ は推定距離、 D は地面です




Figure 9: Distance results from fisheye images on our synthetic dataset. Refer to the supplemental document for more results.

truth in meters. We evaluate the proportion of bad pixels, noted $>x$ in our tables, which represents the percentage of pixel with $E(\theta, \phi) > x$ in the output distance map.

Quantitative Evaluation. We analyze the impact of our adaptive matching. Table 1 shows that our selection of the best camera (Equation (1)) marginally increases quality over naïve variance calculation while reducing the runtime. Using all views is not beneficial for the quality as when a camera’s baseline is aligned with the reference, its contribution for candidate discrimination is low. Simultaneously, using more cameras yields increased computational cost.

	Inverse distance (% m^{-1})				Runtime (ms)	
	>0.1	>0.4	MAE	RMSE	1080 Ti	Xavier
All views (naïve)	14.81	0.57	0.056	0.082	$5.7 \cdot 10^0$	$2.5 \cdot 10^1$
Adaptive matching	12.51	0.55	0.053	0.079	$2.7 \cdot 10^0$	$1.4 \cdot 10^1$

Table 1: Impact of our adaptive matching on the distance quality for 2048×1024 px. All views indicates that we used the variance between all cameras during matching, while adaptive matching uses only the best camera per pixel for cost computation. Runtimes only include cost volume computation.

We compare our inter-scale bilateral filter against the fast bilateral solver [4], the guided filter [16], the fast guided filter [15] and cross-scale cost aggregation [61]. When filtering each slice of the cost volume using the fast bilateral

solver, we use guide precomputation and OpenMP parallelization. We pair cross-scale stereo with a 7×7 box filter for being the best reported runtime and with the guided filter for showing the best results on the Middlebury dataset [47]. We implement cross-scale stereo, the guided filter and the fast guided filter on GPU for fair runtime comparison. We also precompute guide variance and mean for the guided filters and use an aggressive downsampling ratio $s = 4$ for the fast guided filter. For fair comparison, we tune hyperparameters for all competing methods so that RMSE is minimized. For the fast bilateral, we find $\sigma_{xy} = \sigma_l = \sigma_{uv} = 10$ (optimized together) and $\lambda = 385$. For cross-scale is paired with box, we find $\lambda = 17.5$. We find $\varepsilon = 0.105$ for the guided filter and $\varepsilon = 0.63$ for the fast guided filter.

Table 2 shows comparison between different cost aggregation methods. Our method shows competitive results against much more computationally intensive methods such as the bilateral solver [4]. In addition, adaptation and careful implementation of the bilateral solver [36], although achieving high quality depth super-resolution, reports runtimes that are significantly higher than our method while running on dedicated hardware, thus making it unsuitable for real-time cost volume filtering. The guided filters, due to their local nature, are not able to handle large textureless regions and the hyperparameter tuning tend to lead to weak




図 9:合成データセット上の魚眼画像からの距離結果。詳細については、補足資料を参照してください。

メートル単位の真実。表で $>x$ と記載されている不良ピクセルの割合を評価し、出力距離マップで $E(\theta, \phi) > x$ を持つピクセルの割合を表します。

定量的評価。アダプティブマッチングの影響を分析します。表 1は、最適なカメラの選択(式(1))が、分散計算よりも品質がわずかに向上し、ランタイムが短縮されることを示しています。カメラのベースラインが参照と揃っている場合、候補の識別に対する貢献度は低いいため、すべてのビューを使用しても品質にはメリットがありません。同時に、より多くのカメラを使用すると、計算コストが増加します。

	逆距離 (%) m	ランタイム (ms)
0.1 > 0.4 MAE RMSE	1080 Ti Xavier	すべてのビュー (naïve) 14.81
0.57 0.056 0.082 5.7	10 2.5 10	適応マッチング 12.51 0.55 0.053
0.079 2.7 10 1.4 10		

表 1: アダプティブ マッチングが 2048×1024 px の距離品質に与える影響。すべてのビューは、マッチング中にすべてのカメラ間の分散を使用したことを示していますが、アダプティブ マッチングでは、コスト計算にピクセルあたりの最適なカメラのみが使用されます。ランタイムには、コストボリュームの計算のみが含まれます。

スケール間バイラテラル フィルターを、高速バイラテラル ソルバー [4]、ガイド フィルター [16]、高速ガイド フィルター [15]、およびクロススケール コスト集計 [61] と比較します

高速バイラテラルソルバーを使用してコストボリュームの各スライスをフィルタリングする場合、ガイド事前計算と OpenMP 並列化を使用します。クロススケールステレオと 7×7 ボックス フィルターを組み合わせ、最高のレポート ランタイムと、Middlebury データセットで最良の結果を表示するためのガイド付き フィルターを組み合わせます [47]。クロススケールステレオ、ガイド付き フィルター、高速ガイド付き フィルターを GPU に実装し、実行時間を公平に比較します。また、ガイド付き フィルターのガイド分散と平均を事前に計算し、高速ガイド付き フィルターには積極的なダウンサンプリング比 $s = 4$ を使用します。公平な比較のために、RMSE が最小化されるように、競合するすべてのメソッドのハイパーパラメーターを調整します。高速二国間の場合、 $\sigma = \sigma = \sigma = 10$ (一緒に最適化) および $\lambda = 385$ を見つけます。クロススケールがボックスとペアになっている場合、 $\lambda = 17.5$ を見つけます。ガイド フィルターは $\varepsilon = 0.105$ 、高速ガイド フィルターは $\varepsilon = 0.63$ であることがわかります。

表 2 は、さまざまなコスト集計方法の比較を示しています。私たちの方法は、バイラテラルソルバー [4] のようなはるかに計算量の多い方法に対して競争力のある結果を示しています。さらに、バイラテラルソルバー [36] の適応と慎重な実装は、高品質の深度超解像を達成しますが、専用のハードウェアで実行している間は、私たちの方法よりも大幅に高いランタイムを報告するため、リアルタイムのコストボリュームフィルタリングには適していません。ガイド付き フィルターは、そのローカルな性質のために、大きな

	Inverse distance (% m ⁻¹)				Runtime (ms)	
	>0.1	>0.4	MAE	RMSE	1080 Ti	Xavier
Fast bilateral solver [4]	12.52	0.58	0.054	0.081	3.7·10 ²	1.4·10 ³
Guided filter [16]	32.08	8.89	0.136	0.238	1.4·10 ²	2.9·10 ²
Fast guided filter [15]	34.18	8.34	0.135	0.232	1.5·10 ¹	5.0·10 ¹
Cross-scale + Box [61]	17.40	0.93	0.062	0.093	3.8·10 ¹	6.4·10 ¹
C-S + G-F [61, 16]	17.39	2.03	0.070	0.115	2.4·10 ²	4.6·10 ²
Ours	12.51	0.55	0.053	0.079	3.5·10⁰	1.0·10¹

Table 2: Comparison of our cost aggregation on the distance quality for 2048×1024 px with other filtering methods. Note that we implement all methods on GPU except the fast bilateral solver that benefits from a multithreaded implementation. Our method shows competitive accuracy while being orders of magnitude faster.

guidance, with large regularization parameters ε . Cross-scale cost aggregation [61] is able to efficiently handle large textureless regions. However, due to the absence of inter-scale guidance, it is not able to maintain edge preservation even when paired with the guided filter.

We compare distance accuracy of our method against four distance from fisheye methods [33, 59, 58, 26] and three distance from rectified spherical stereo image pairs [31, 35, 56]. As we use their rigs layout, we do not retrain data driven methods. To compare against 360SD-Net [56], we used the pretrained weights that show the lowest RMSE. Due to the high computational requirements of weighted thin plate smoothing, we omit post processing from [35]. Li et al. [31, 32, 30] propose a rectification to allow for standard stereo algorithms to run on spherical images. For fair comparison, we paired it with a more recent and highly optimized SGM implementation on GPU [18]. We also implement Lin et al.’s [33] method on GPU.

Table 3 shows that our method significantly outperforms both analytical and data driven methods on our rendered dataset while being orders of magnitude more computationally efficient. In addition, as the three depth from spherical image pair methods [56, 35, 32] are unable to estimate depth in the baseline’s alignment, the distance estimation quality is highly degraded, hence their substantial >0.4 bad pixel ratio. We do not evaluate the panorama quality for these method as we use the rendered panoramas as input, ignoring possible stitching artifacts that may occur in real world scenarios. Figures 7, 9 and 10 show that our method is able to estimate distance accurately using our prototype, while providing a convincing panorama. Refer to the supplemental document for additional comparisons.

5. Conclusion

Our work achieves real-time omnidirectional RGB-D imaging directly from fisheye images. The method does not rely on temporal information nor on special illumina-

* CrownConv inference runs with a fixed number of vertices (10242).

† no reference implementation is provided.

‡ part of the method runs on CPU.




Figure 10: Image stitching results on our synthetic dataset.

	Inverse distance (% m ⁻¹)				Panorama		Runtime (ms)
	>0.1	>0.4	MAE	RMSE	PSNR	SSIM	
CrownConv* [26]	57.09	2.53	0.135	0.168	36.35	0.985	5.2·10 ²
OmniMVS† [58]	39.01	5.64	0.124	0.182	37.28	0.986	1.3·10 ³
Sweepnet‡ [59]	37.13	3.00	0.101	0.133	35.46	0.981	1.0·10 ⁵
Lin et al.† [33]	37.25	5.13	0.181	0.181	36.22	0.980	2.5·10 ³
360SD-Net [56]	54.29	13.27	0.212	0.341	–	–	6.1·10 ²
Matzen et al.†‡ [35]	29.59	18.64	0.170	0.275	–	–	9.3·10 ¹
Li + SGM [32, 18]	31.04	16.85	0.170	0.283	–	–	5.8·10 ⁰
Ours	20.38	0.56	0.068	0.095	38.78	0.990	2.8·10⁰

Table 3: Comparison of our spherical RGB-D results against other methods. All methods are run on our desktop test system and output a 1024×512 px distance map. Note that since [56, 35, 32] inputs are ground truth panoramas, the image quality is not directly comparable.

tion making it robust to changing scenes and suitable for both indoor and outdoor situations. Thanks to our adaptive spherical matching and fast inter-scale bilateral filtering, we demonstrate a combination of accuracy and performance suitable for interactive and robotic applications in dynamic environments.

Acknowledgments

Min H. Kim acknowledges Samsung Research Funding Center (SRFC-IT2001-04) for developing partial 3D imaging algorithms, in addition to partial support of Korea NRF grants (2019R1A2C3007229, 2013M3A6A6073718), MSIT/IITP of Korea (2017-0-00072), and MSRA.

	逆距離 (%) m)	ランタイム (ms)
0.1 >0.4 MAE RMSE 1080		
0.136 0.238 1.4・10 2.9・10	高速ガイドフィルタ [16]	32.08 8.89
0.232 1.5・10 5.0・10	クロススケール+ボックス [61]	17.40 0.93 0.062
0.093 3.8・10 6.4・10	C-S + G-F [61, 16]	17.39 2.03 0.070 0.115 2.4・10
4.6・10	私たちの	12.51 0.55 0.053 0.079 3.5・10 1.0・10

表 2: 2048×1024 px の距離品質に関するコスト集計と他のフィルタリング方法との比較。マルチスレッド実装の恩恵を受ける高速バイラテラルソルバーを除くすべてのメソッドをGPUに実装することに注意してください。私たちの方法は、桁違いに高速でありながら、競争力のある精度を示しています。

ガイダンス、大きな正則化パラメータε。クロススケールのコスト集計 [61] は、テクスチャのない大きな領域を効率的に処理できます。ただし、スケール間ガイダンスがないため、ガイドフィルターと組み合わせてもエッジの保持を維持できません。

この手法の距離精度を、魚眼法からの 4 つの距離 [33、59、58、26] および整流球面ステレオ イメージ ペアからの 3 つの距離 [31、35、56] と比較します。リグのレイアウトを使用しているため、データ駆動型のメソッドを再トレーニングすることはありません。360SDNet [56] と比較するために、RMSE が最も低いことを示す事前学習済みの重みを使用しました。加重薄板スプージングの計算要件が高いため、[35] から後処理を省略します。Liら[31、32、30]は、標準的なステレオアルゴリズムを球面画像上で実行できるようにするための修正を提案しています。公平な比較のために、GPU でのより新しく高度に最適化されたSGM 実装と組み合わせています [18]。

また、Lin et al. [33] の手法を GPU に実装します。表 3は、レンダリングされたデータセットで、私たちの方法が分析方法とデータ駆動型の方法の両方を大幅に上回り、計算効率が桁違いに向上していることを示しています。さらに、球面画像ペア法[56、35、32]の3つの深度は、ベースラインのアライメントの深さを推定できないため、距離推定の品質が大幅に低下し、したがって、ピクセル比が>0.4と大幅に低下します。これらの方法では、レンダリングされたパノラマを入力として使用し、実際のシナリオで発生する可能性のあるステッチアーティファクトを無視するため、パノラマ品質は評価しません。図 7、図 9、図 10は、私たちの方法がプロトタイプを使用して距離を正確に推定し、説得力のあるパノラマを提供できることを示しています。その他の比較については、補足資料を参照してください。

5. 結論 私たちの仕事は、魚眼画像から直接リアルタイムの全方向 RGB-D イメージングを実現します。この方法は、時間情報にも特別な照明にも依存しません。

* CrownConv 推論は、固定数の頂点 (10242) で実行されます。
 † 参照実装は提供されていません。
 ‡ メソッドの一部はCPUで実行されます。




図 10:合成データセットでの画像のスティッチング結果。

	逆距離 (%) m)	パノラマ ランタイム
0.1 >0.4 MAE RMSE PSNR SSIM (ms) CrownConv[26]	57.09 2.53 0.135	
0.168 36.35 0.985 5.2・10	OmniMVS[58]	39.01 5.64 0.124 0.182 37.28
0.986 1.3・10	スワイプネット [59]	37.13 3.00 0.101 0.133 35.46 0.981 1.0・10
Lin et al.[33]	37.25 5.13 0.181 0.181 36.22 0.980 2.5・10	360SD-Net [56]
	54.29 13.27 0.212 0.341	-
Matzen et al.[35]	29.59 18.64 0.170 0.275 - 9.3・10	Li + SGM [32, 18]
31.04 16.85 0.170 0.283 - 5.8・10	Ours	20.38 0.56 0.068 0.095 38.78 0.990 2.8・10

表 3:球面 RGB-Dの結果と他の方法との比較。すべてのメソッドはデスクトップテストシステムで実行され、1024×512ピクセルの距離マップを出力します。[56, 35, 32] 入力グラウンド トゥルース パノラマであるため、画質は直接比較できないことに注意してください。これにより、変化するシーンに対して堅牢で、屋内と屋外の両方の状況に適しています。適応性のある球面マッチングと高速なスケール間バイラテラルフィルタリングにより、ダイナミックな環境でのインタラクティブおよびロボットアプリケーションに適した精度と性能の組み合わせを実証しています。

確認

Min H. Kim は、Samsung Research Funding Center (SRFC-IT2001-04) がパーシャル 3D イメージングアルゴリズムの開発を行ったほか、韓国の NRF 助成金 (2019R1A2C3007229, 2013M3A6A6A6073718)、韓国の MSIT/IITP (2017-0-00072)、MSRA の部分的な支援も受け、この研究に貢献しました。

References

- [1] Robert Anderson, David Gallup, Jonathan T. Barron, Janne Kontkanen, Noah Snavely, Carlos Hernandez Esteban, Sameer Agarwal, and Steven M. Seitz. Jump: Virtual reality video. *ACM Transactions on Graphics (Proc. SIGGRAPH Asia)*, 2016.
- [2] Z. Arican and P. Frossard. Dense disparity estimation from omnidirectional images. In *2007 IEEE Conference on Advanced Video and Signal Based Surveillance*, pages 399–404, 2007.
- [3] Iro Armeni, Sasha Sax, Amir R Zamir, and Silvio Savarese. Joint 2d-3d-semantic data for indoor scene understanding. *arXiv preprint arXiv:1702.01105*, 2017.
- [4] Jonathan T. Barron and Ben Poole. The fast bilateral solver. *ECCV*, 2016.
- [5] Tobias Bertel, Mingze Yuan, Reuben Lindroos, and Christian Richardt. OmniPhotos: Casual 360° VR photography. *ACM Transactions on Graphics*, 39(6):266:1–12, Dec. 2020.
- [6] Michael Broxton, John Flynn, Ryan Overbeck, Daniel Erickson, Peter Hedman, Matthew Duvall, Jason Dourgarian, Jay Busch, Matt Whalen, and Paul Debevec. Immersive light field video with a layered mesh representation. *ACM Transactions on Graphics (TOG)*, 39(4):86–1, 2020.
- [7] D. Caruso, J. Engel, and D. Cremers. Large-scale direct slam for omnidirectional cameras. In *2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 141–148, 2015.
- [8] Angel Chang, Angela Dai, Thomas Funkhouser, Maciej Halber, Matthias Niessner, Manolis Savva, Shuran Song, Andy Zeng, and Yinda Zhang. Matterport3D: Learning from RGB-D data in indoor environments. *International Conference on 3D Vision (3DV)*, 2017.
- [9] Jiawen Chen, Andrew Adams, Neal Wadhwa, and Sam Hasinoff. Bilateral guided upsampling. *ACM Transactions on Graphics (Proceedings of SIGGRAPH Asia 2016)*, 2016.
- [10] Jiawen Chen, Sylvain Paris, and Frédo Durand. Real-time edge-aware image processing with the bilateral grid. *ACM Trans. Graph.*, 26(3):103–es, July 2007.
- [11] Zhaopeng Cui, Lionel Heng, Y. Yeo, Andreas Geiger, M. Pollefeys, and Torsten Sattler. Real-time dense mapping for self-driving vehicles using fisheye cameras. *2019 International Conference on Robotics and Automation (ICRA)*, pages 6087–6093, 2019.
- [12] F. Devernay and O. Faugeras. Straight lines have to be straight. In *Machine Vision and Applications*, 2001.
- [13] W. Gao and S. Shen. Dual-fisheye omnidirectional stereo. *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 6715–6722, 2017.
- [14] Eduardo S. L. Gastal and Manuel M. Oliveira. Domain transform for edge-aware image and video processing. *ACM TOG*, 30(4):69:1–69:12, 2011. Proceedings of SIGGRAPH 2011.
- [15] Kaiming He and Jian Sun. Fast guided filter. *ArXiv*, abs/1505.00996, 2015.
- [16] Kaiming He, Jian Sun, and Xiaoou Tang. Guided image filtering. In Kostas Daniilidis, Petros Maragos, and Nikos Paragios, editors, *Computer Vision – ECCV 2010*, pages 1–14, Berlin, Heidelberg, 2010. Springer Berlin Heidelberg.
- [17] S. Hermann and T. Vaudrey. The gradient - a powerful and robust cost function for stereo matching. In *2010 25th International Conference of Image and Vision Computing New Zealand*, pages 1–8, 2010.
- [18] Daniel Hernandez-Juarez, Alejandro Chacón, Antonio Espinosa, David Vázquez, Juan Carlos Moure, and Antonio M. López. Embedded real-time stereo estimation via semi-global matching on the GPU. In *International Conference on Computational Science 2016, ICCS 2016, 6-8 June 2016, San Diego, California, USA*, pages 143–153, 2016.
- [19] H. Hirschmuller. Accurate and efficient stereo processing by semi-global matching and mutual information. In *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’05)*, volume 2, pages 807–814 vol. 2, 2005.
- [20] T. Ho, I. D. Schizas, K. R. Rao, and M. Budagavi. 360-degree video stitching for dual-fisheye lens cameras based on rigid moving least squares. In *2017 IEEE International Conference on Image Processing (ICIP)*, pages 51–55, 2017.
- [21] Tuan Anh Ho and Madhukar Budagavi. Dual-fisheye lens stitching for 360-degree imaging. *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 2172–2176, 2017.
- [22] Christian Häne, Lionel Heng, Gim Lee, Alexey Sizov, and Marc Pollefeys. Real-time direct dense matching on fisheye images using plane-sweeping stereo. pages 57–64, 02 2015.
- [23] Sunghoon Im, Hyowon Ha, François Rameau, Hae-Gon Jeon, Gyeongmin Choe, and In So Kweon. All-around depth from small motion with a spherical panoramic camera. In *European Conference on Computer Vision*, pages 156–172. Springer, 2016.
- [24] Jose M. Alvarez Jiayu Yang, Wei Mao and Miaomiao Liu. Cost volume pyramid based depth inference for multi-view stereo. In *CVPR*, 2020.
- [25] J. Kannala and S. S. Brandt. A generic camera model and calibration method for conventional, wide-angle, and fish-eye lenses. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 28(8):1335–1340, 2006.
- [26] Ren Komatsu, Hiromitsu Fujii, Yusuke Tamura, Atsushi Yamashita, and Hajime Asama. 360° depth estimation from multiple fisheye images with origami crown representation of icosahedron. In *IROS*, 2020.
- [27] Johannes Kopf, Michael Cohen, Dani Lischinski, and Matt Uyttendaele. Joint bilateral upsampling. In *ACM Transactions on Graphics (Proceedings of SIGGRAPH 2007)*, volume 26. Association for Computing Machinery, Inc., August 2007.
- [28] Po Kong Lai, Shuang Xie, Jochen Lang, and Robert Laquière. Real-time panoramic depth maps from omnidirectional stereo images for 6 DOF videos in virtual reality. In *2019 IEEE Conference on Virtual Reality and 3D User Interfaces (VR)*, pages 405–412. IEEE, 2019.
- [29] Jongchul Lee, Daeyoon Jun, Changyoung Eem, and Hyunki Hong. Improved census transform for noise robust stereo matching. *Optical Engineering*, 55(6):1 – 10, 2016.

参照

[1] ロバート・アンダーソン、デビッド・ギャラップ、ジョナサン・T・バロン、ヤンネ・コントカネン、ノア・スナブリー、カルロス・ヘルナンデス・エステバン、サミール・アガルワル、ステイビデオ。ACM Transactions on Graphics (Proc. SIGGRAPH Asia), 2016 年。

[2] Z.アリカンとP.フロサード。からの密な視差の推定全方向画像。2007 IEEE Conference on Advanced Video and Signal Based Surveillance、399-404ページ、2007 年。

[3] イロ・アルメニ、サーシャ・サックス、アミール・R・ザミール、屋内シーンの理解のための共同 2D-3D-セマンティックデータ。arXivプレプリントarXiv:1702.01105、2017 年。

[4] ジョナサン・T・バロンとベン・プール。高速な両側ソルバー。ECCV、2016 年。

[5] トビアス・ベルテル、ミンゼ・ユアン、ルーベン・リンドロース、クリスチャン・リチャード。OmniPhotos:カジュアルな 360°VR 撮影。ACM Transactions on Graphics, 39(6):266:1-12, 2020 年 12 月.[6] マイケル・ブロクストン、ジョン・フリン、ライアン・オーバーベック、ダニエル・エリクソン、ピーター・ヘドマン、マシュー・デュバル、ジェイソン・ドルガリアン、ジェイ・ブッシュ、マット・ウェイレン、ポール・デベベック。レイヤードメッシュ表現の没入型ライトフィールドビデオ。ACM Transactions on Graphics(TOG)、39(4):86-1、2020 年。[7] D.カルーソ、J.エンゲル、D.クレマーズ。全方位カメラ用の大規模なダイレクトスラム。2015 年、IEEE/RSJ インターナ-

[8] アンヘル・チャン、アンジェラ・ダイ、トーマス・ファンクハウザー、マチェイ・ハルバー、マティアス・ニースナー、マノリス・サヴァ、シュラン・ソング、アンディ・ゼン、インダ・チャン。Matterport3D:屋内環境でのRGBDデータから学習します。3Dビジョンに関する国際会議(3DV)、2017 年。

[9] Jiawen Chen、Andrew Adams、Neal Wadhwa、Sam Hasinoff。バイラテラルガイド付きアップサンプリング。ACM Transactions on Graphics (Proceedings of SIGGRAPH Asia 2016)、2016 年。

[10] Jiawen Chen、Sylvain Paris、およびFr'edo Durand。リアルタイムバイラテラルグリッドによるエッジアウェアな画像処理。ACM Trans. Graph., 26(3):103-es, 2007 年 7 月。

[11] Zhaopeng Cui、Lionel Heng、Y. Yeo、Andreas Geiger、M. Pollefeys、およびTorsten Sattler。魚眼カメラを使用した自動運転車両のリアルタイム高密度マッピング。2019 International Conference on Robotics and Automation(ICRA)、6087~6093ページ、2019 年。

[12] F.デヴェルネイとO.ファウゲラス。直線は直線でなければなりません。マシンビジョンとアプリケーション、2001 年。

[13] W.ガオとS.シェン。デュアル魚眼全方向性ステレオ。2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 6715-6722, 2017.

[14] エドゥアルド・S・L・ガスタルとマヌエル・M・オリベイラ。ドメインエッジ対応の画像およびビデオ処理のための変換。ACM TOG, 30(4):69:1-69:12, 2011.SIGGRAPH 2011の議事録。

[15] Kaiming HeとJian Sun。ArXiv、abs/1505.00996、2015 年。

[16] Kaiming He、Jian Sun、Xiaoou Tang。ガイド付き画像ファ

[17] S.ヘルナンデス・ベルテル。グラデーション - 強力でステレオマッチングのための堅牢なコスト関数。In 2010 25th International Conference of Image and Vision Computing New Zealand, pages 1-8, 2010.

[18] ダニエル・ヘルナンデス・フアレス、アレハンドロ・チャコン、アントニオ・エスピノーサ、デビッド・バスケス、フアン・カルロス・ヘン。セミグローバルマッチングによる組み込みリアルタイムステレオ推定。International Conference on Computational Science 2016, ICCS 2016, 2016 年 6 月 6-8 シルヴ

[19] H.ヒルシュミュラー。正確で効率的なステレオ処理セミグローバルマッチングと相互情報量によって。2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), volume 2, pages 807-814, vol. 2, 2005.

[20] T.ホー、I.D.シザス、KRラオ、M.ブダガビ。360-剛体移動最小二乗法に基づくデュアル魚眼レンズ カメラのデ

[21] トゥアン・アイン・ホーとマドゥカル・ブダガビ。デュアル魚眼レンズ 360 度イメージングのためのステッチ。2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pages 2172-2176, 2017.

[22] クリスチャン・H'ane、ライオネル・ヘン、ギム・リー、アレクセイ・シゾフ、そしてフ・ポルフィーズ。プレーンスイープステレオを使用した魚眼画像でのリアルタイムの直接密なマッチング。57-64、2015 年 3 月 2 日。

[23] 2015 年 3 月 2 日、ヒョウォン、フラン・ラモー、ヘゴンチョン、チェ・ギョンミン、イン・ソクォン。球面パノラマカメラによる小さな動きから全方位の深さ。コンピュータビジョンに関するヨーロッパ会議、156~172ページ。スプリンガー、2016 年。

[24] ホセ・M・アルバレス・ジアユ・ヤン、ウェイ・マオ、ミャオミャオ・リウ。マルチビューステレオのコストボリュームピラミッドベースの深度推論。CVPRでは、2020 年。

[25] J.カンナラとSSブランド。汎用カメラモデルとキャリブレーション従来レンズ、広角レンズ、魚眼レンズのIBRATION 法。IEEE Transactions on Pattern Analysis and Machine Intelligence, 28(8):1335-1340, 2006.

[26] 小松 蓮、藤井 弘光、田村 祐介、矢 淳 mashita、そして浅間一。二十面体の折り紙クラウン表現による複数の魚眼画像からの360 深度推定。2020 年、イロス島で。

[27] ヨハネス・コップフ、マイケル・コーエン、ダニ・リシンスキー、マツト Uyttendaele。共同二国間アップサンプリング。ACM Transactions on Graphics(Proceedings of SIGGRAPH 2007)、第 26 巻。Association for Computing Machinery, Inc., 2007 年 8 月。

[28] ポー・コン・ライ、シュアン・シエ、ヨッチェン・ラン、ロバートラカルエレ。バーチャルリアリティの6 自由度ビデオの全方向性ステレオ画像からのリアルタイムのパノラマ深度マップ。2019 年のバーチャルリアリティと3Dユーザーインターフェイス(VR)に関するIEEE 会議、405~412ページ。IEEE、2019 年。

[29] イ・ジョンチョル、ジュン・デユン、エム・チャンギョン、ヒョンギ香港。ノイズの堅牢なステレオマッチングのための国勢調査変換の改善。光工学, 55(6):1 - 10, 2016.

- [30] Shigang Li. Binocular spherical stereo. *IEEE Transactions on intelligent transportation systems*, 9(4):589–600, 2008.
- [31] Shigang Li and Kiyotaka Fukumori. Spherical stereo for the construction of immersive VR environment. In *IEEE Proceedings. VR 2005. Virtual Reality, 2005.*, pages 217–222. IEEE, 2005.
- [32] Li, Shigang. Real-time spherical stereo. In *18th International Conference on Pattern Recognition (ICPR’06)*, volume 3, pages 1046–1049, 2006.
- [33] Hong-Shiang Lin, Chao-Chin Chang, Hsu-Yu Chang, Yung-Yu Chuang, Tzong-Li Lin, and Ming Ouhyoung. A low-cost portable polycamera for stereoscopic 360° imaging. *IEEE Transactions on Circuits and Systems for Video Technology*, 2018.
- [34] Chuiwen Ma, Liang Shi, Hanlu Huang, and Mengyuan Yan. 3d reconstruction from full-view fisheye camera. *arXiv preprint arXiv:1506.06273*, 2015.
- [35] Kevin Matzen, Michael F Cohen, Bryce Evans, Johannes Kopf, and Richard Szeliski. Low-cost 360 stereo photography and video capture. *ACM Transactions on Graphics (TOG)*, 36(4):148, 2017.
- [36] Amrita Mazumdar, Armin Alaghi, Jonathan T. Barron, David Gallup, Luis Ceze, Mark Oskin, and Steven M. Seitz. A hardware-friendly bilateral solver for real-time virtual reality video. In *Proceedings of High Performance Graphics, HPG ’17*, New York, NY, USA, 2017. Association for Computing Machinery.
- [37] Morgan McGuire. Computer graphics archive, July 2017. <https://casual-effects.com/data>.
- [38] M. Menze and A. Geiger. Object scene flow for autonomous vehicles. In *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3061–3070, 2015.
- [39] Branislav Micusík and Tomáš Pajdla. Estimation of omnidirectional camera model from epipolar geometry. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pages 485–490, 2003.
- [40] Simon Niklaus and Feng Liu. Softmax splatting for video frame interpolation. In *CVPR*, 2020.
- [41] Manuel Oliveira, Brian Bowen, Richard McKenna, and Yu-Sung Chang. Fast digital image inpainting. *VIIIP*, pages 261–266, 01 2001.
- [42] Sarthak Pathak, Alessandro Moro, Atsushi Yamashita, and Hajime Asama. Dense 3D reconstruction from two spherical images via optical flow-based equirectangular epipolar rectification. In *2016 IEEE International Conference on Imaging Systems and Techniques (IST)*, pages 140–145. IEEE, 2016.
- [43] Eric Penner and Li Zhang. Soft 3D reconstruction for view synthesis. In *ACM Transactions on Graphics (Proc. SIGGRAPH Asia)*. ACM, 2017.
- [44] Albert Pozo, Michael Toksvig, Terry Schrager, Joyce Hsu, Uday Mathur, Alexander Sorkine-Hornung, Rick Szeliski, and Brian Cabral. An integrated 6DoF video camera and system design. *ACM Transactions on Graphics*, 38:1–16, 11 2019.
- [45] Menandro Roxas and Takeshi Oishi. Real-time variational fisheye stereo without rectification and undistortion. *arXiv preprint arXiv:1909.07545*, 2019.
- [46] M. Roxas and T. Oishi. Variational fisheye stereo. *IEEE Robotics and Automation Letters*, 5(2):1303–1310, 2020.
- [47] D. Scharstein, R. Szeliski, and R. Zabih. A taxonomy and evaluation of dense two-frame stereo correspondence algorithms. In *Proceedings IEEE Workshop on Stereo and Multi-Baseline Vision (SMBV 2001)*, pages 131–140, 2001.
- [48] M. Schönbein and A. Geiger. Omnidirectional 3d reconstruction in augmented manhattan worlds. In *2014 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 716–723, 2014.
- [49] Christophe Seux. Blender demo files, November 2020. blender.org/download/demo-files/.
- [50] Tomáš Svoboda, Tomáš Pajdla, and Václav Hlaváč. Epipolar geometry for panoramic cameras. In Hans Burkhardt and Bernd Neumann, editors, *ECCV*, 1998.
- [51] Xiao Tang, Xiaowei Hu, Chi-Wing Fu, and Daniel Cohen-Or. GrabAR: Occlusion-aware grabbing virtual objects in AR. *UIST*, 2020.
- [52] Akihiko Torii, Atsushi Imiya, and Naoya Ohnishi. Two- and three- view geometry for spherical cameras. In *workshop on omnidirectional vision, camera networks and non-classical cameras*, 2005.
- [53] V. Usenko, N. Demmel, and D. Cremers. The double sphere camera model. In *Proc. of the Int. Conference on 3D Vision (3DV)*, September 2018.
- [54] Fu-En Wang, Hou-Ning Hu, Hsien-Tzu Cheng, Juan-Ting Lin, Shang-Ta Yang, Meng-Li Shih, Hung-Kuo Chu, and Min Sun. Self-supervised learning of depth and camera motion from 360° videos. *ACCV*, 2018.
- [55] Fu-En Wang, Yu-Hsuan Yeh, Min Sun, Wei-Chen Chiu, and Yi-Hsuan Tsai. BiFuse: Monocular 360 depth estimation via bi-projection fusion. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- [56] Ning-Hsu Wang, Bolivar Solarte, Yi-Hsuan Tsai, Wei-Chen Chiu, and Min Sun. 360SD-Net: 360° stereo depth estimation with learnable cost volume. In *ICRA*, 2020.
- [57] Yan Wang, Zihang Lai, Gao Huang, Brian H. Wang, Laurens Van Der Maaten, Mark Campbell, and Kilian Q Weinberger. Anytime stereo image depth estimation on mobile devices. *International Conference on Robotics and Automation (ICRA)*, 2019.
- [58] Changhee Won, Jongbin Ryu, and Jongwoo Lim. OmniMVS: End-to-end learning for omnidirectional stereo matching. In *ICCV*, 2019.
- [59] Changhee Won, Jongbin Ryu, and Jongwoo Lim. SweepNet: Wide-baseline omnidirectional depth estimation. In *ICRA*, 2019.
- [60] Andy Zeng, Shuran Song, Johnny Lee, Alberto Rodriguez, and Thomas Funkhouser. TossingBot: Learning to throw arbitrary objects with residual physics. 2019.
- [61] K. Zhang, Y. Fang, D. Min, L. Sun, S. Yang, and S. Yan. Cross-scale cost aggregation for stereo matching. *IEEE Transactions on Circuits and Systems for Video Technology*, 27(5):965–976, 2017.
- [62] Nikolaos Zioulis, Antonis Karakottas, Dimitrios Zarpalas, and Petros Daras. Omnidepth: Dense depth estimation for indoors spherical panoramas. In *ECCV*, pages 453–471, 2018.

- [30] Shigang Li. 双眼球面ステレオ。高度道路交通システムに関するIEEEトランザクション、9(4):589–600、2008年。[31] Shigang Li と Kiyotaka Fukumori.のための球状ステレオ没入型VR環境の構築。IEEE議事録で。VR 2005年。バーチャルリアリティ、2005年、217–222ページ。IEEE, 2005。 [C](#)
- [32] 李、石剛。リアルタイムの球面ステレオ。第18回インターナショナルパターン認識に関する会議(ICPR'06)、第3巻、1046–1049ページ、2006年。
- [33] Hong-Shiang Lin, Chao-Chin Chang, Hsu-Yu Chang, Yung-Yu・チュアン、ツォンリー・リン、ミン・オウヨン。立体視360度イメージング用の低コストのポータブルポリカメラ。ビデオ技術の回路とシステムに関するIEEEトランザクション、2018年。 [C](#)
- [34] Chuiwen Ma, Liang Shi, Hanlu Huang, and Mengyuan Yan. 3d reconstruction from full-view fisheye camera. arXiv preprint arXiv:1506.06273, 2015。 [C](#)
- [35] Kevin Matzen, Michael F Cohen, Bryce Evans, Johannes コップフ、リチャード・セリスキー。低コストの360ステレオ写真とビデオキャプチャ。ACM Transactions on Graphics(TOG)、36(4):148、2017年。 [C](#)
- [36] Amrita Mazumdar, Armin Alaghi, Jonathan T. Barron, David ギャラップ、ルイス・セゼ、マーク・オスキンの、ステイブ・M・ザイツ。リアルタイムのバーチャルリアリティビデオ用のハードウェアフレンドリーなバイラテラルソルバー。ハイパフォーマンスグラフィックスの議事録、HPG '17、ニューヨーク、ニューヨーク、米国、2017年。コンピューティング機 [C](#)
- [37] モーガン・マクガイア。コンピュータグラフィックスアーカイブ、2017年7月。 <https://casual-effects.com/data>。
- [38] M. Menze and A. Geiger. Object scene flow for autonomous 車。2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)、3061–3070ページ、2015年。 [C](#)
- [39] Frantisek Micusík and Tomáš Pajdla. Estimation of omni-エピポーラ形状からの指向性カメラモデル。IEEE Computer Society Conference on Computer Vision and Pattern Recognition、485–490ページ、2003年。 [C](#)
- [40] Simon Niklaus and Feng Liu. Softmax splatting for video frame interpolation. In CVPR, 2020。[41] Manuel Oliveira, Brian Bowen, Richard McKenna, and Yu-ソン・チャン。高速デジタル画像インペインティング。VIIP、261–266ページ、2001年1月1日。 [C](#)
- [42] Sarthak Pathak, Alessandro Moro, Atsushi Yamashita, and 浅間一。オプティカルフローベースの正距円筒エピポーラ整流による2つの球面画像からの高密度3D再構成。2016年、IEEE International Conference on Imaging Systems and Techniques(IST)、140–145ページ。IEEEの2016年。 [C](#)
- [43] エリック・ペナーとリー・チャン。ビューのためのソフト3D再構築合成。ACM Transactions on Graphics(Proc. SIGGRAPH Asia)で。ACM、2017年。 [C](#)
- [44] Albert Pozo, Michael Toksvig, Terry Schrager, Joyce Hsu, ウダイ・マトゥール、アレクサンダー・ソーキン・ホーナン、リック・セリスキー、ブライアン・カブラル。統合された6DoFビデオカメラとシステム設計。グラフィックスに関するACMトランザクション、38:1–16、2019年11月11日。 [C](#)
- [45] メナンドロ・ロハスと大石武。リアルタイム変分法整流と歪み補正のない魚眼ステレオ。arXivプレプリント arXiv:1909.07545、2019年。 [C](#)
- [46] M. Roxas と T. Oishi.変分魚眼ステレオ。IEEE Robotics and Automation Letters, 5(2):1303–1310、2020。[47] D.シャースタイン、R.シェリスキー、R.ザビ。分類法と高密度2フレームステレオ対応アルゴリズムの評価。Proceedings IEEE Workshop on Stereo and MultiBaseline Vision (SMBV 2001), pages 131–140, 2001。 [C](#)
- [48] M. Schöonbein and A. Geiger. Omnidirectional 3d reconstructionされたマンハッタンの世界での構造。2014 IEEE/RSJ International Conference on Intelligent Robots and Systems, pages 716–723, 2014。 [C](#)
- [49] Christophe Seux. Blender demo files, November 2020。 blender.org/download/demo-files/。 [C](#)
- [50] Tomáš Svoboda, Tomáš Pajdla, and Václav Hlaváč. Epipolar geometry for panoramic cameras. In Hans Burkhardt and Bernd Neumann, editors, ECCV, 1998。 [C](#)
- [51] Xiao Tang, Xiaowei Hu, Chi-Wing Fu, and Daniel Cohen-または、GrabAR:ARでのオクルージョン対応の仮想オブジェクトのつかみ取りUIST、2020年。 [C](#)
- [52] Akihiko Torii, Atsushi Imiya, and Naoya Ohnishi. Two- and 球面カメラ用の3ビュージオメトリ。2005年、全方位ビジョン、カメラネットワーク、非古典的カメラに関するワークショップで。 [C](#)
- [53] V. Usenko、N. Demmel、および D. Cremers。二重球カメラモデル。Int. Conference on 3D Vision (3DV), 2018年9月。 [C](#)
- [54] Fu-En Wang, Hou-Ning Hu, Hsien-Tzu Cheng, Juan-Ting Lin, Shang-Ta Yang, Meng-Li Shih, Hung-Kuo Chu, and Min Sun. Self-supervised learning of depth and camera motion from 360videos. ACCV, 2018。 [C](#)
- [55] Fu-En Wang, Yu-Hsuan Yeh, Min Sun, Wei-Chen Chiu, and Yi-Hsuan Tsai. BiFuse:バイプロジェクトンフュージョンによる単眼360度深度推定。2020年6月、IEEE/CVF Conference on Computer Vision and Pattern [C](#)
- [56] Ning-Hsu Wang, Bolivar Solarte, Yi-Hsuan Tsai, Wei-Chen 360SD-Net:学習可能なコストボリュームによる360ステレオ深度推定。ICRAでは、2020年。 [C](#)
- [57] Yan Wang, Zihang Lai, Gao Huang, Brian H. Wang, Laurens Van Der Maaten、Mark Campbell、Kilian Q Weinberger。モバイルデバイスでのいつでもステレオ画像の深度推定。ロボティクスとオートメーションに関する国際会議(ICRA)、2019年。 [C](#)
- [58] Changhee Won, Jongbin Ryu, and Jongwoo Lim. OmniMVS:全方向性ステレオマッチングのためのエンドツーエンド学習。ICCV、2019年。 [C](#)
- [59] Changhee Won, Jongbin Ryu, and Jongwoo Lim. SweepNet: Wide-baseline omnidirectional depth estimation. In ICRA, 2019。 [C](#)
- [60] Andy Zeng, Shuran Song, Johnny Lee, Alberto Rodriguez, とトーマス・ファンクハウザー。TossingBot: 残差物理を持つ任意の物体を投げる方法を学びます。2019。 [C](#)
- [61] K. Zhang, Y. Fang, D. Min, L. Sun, S. Yang, and S. Yan. ステレオマッチングのためのクロススケールコスト集計。ビデオ技術のための回路とシステムに関するIEEEトランザクション、27(5):965–976、2017年。 [C](#)
- [62] ニコラオス・ジオリス、アントニス・カラコッタス、ディミトリオス・ザルパラス、とペトロス・ダラス。OmniDepth: 屋内の球面パノラマの密な深度推定。ECCV、453–471ページ、2018年。 [C](#)